Card2Contact

Лаб. 2 «Хмарні обчислення»

Розпізнавання візиток з фото через Google Gemini API

Тертичний Тарас, ТК-42

Проблема

Після зустрічі чи конференції — стос візиток. Переписувати кожну в телефон вручну довго, і легко помилитися в цифрі чи email.

Існуючі інструменти:

- **Google Lens** — закрите рішення, не вбудовується у власний продукт.
- **Застосунки-сканери візиток** — окремі закриті продукти, часто з підпискою.
- **Tesseract OCR** — дає суцільний текст: не знає, де ім'я, а де компанія.

Ідея: один виклик публічного multimodal AI API: фото $\rightarrow$ готові поля $\rightarrow$ файл vCard для телефону.

Штучний інтелект як хмарний сервіс

Хмара — обчислювальні ресурси за запитом з оплатою за використання.

Модель	Що надає провайдер	Приклади
IaaS Infrastructure as a Service	віртуальні машини, мережі, диски	Compute Engine, AWS EC2
PaaS Platform as a Service	платформу для запуску коду	Cloud Run, Azure App Service
SaaS Software as a Service	готовий застосунок	Gmail, Google Docs
AIaaS Artificial Intelligence as a Service	**готову AI-модель через API**	**Gemini API, Azure OpenAI**

Підсумок: проєкт — споживач AIaaS: не навчаємо й не розміщуємо модель, не купуємо GPU, лише викликаємо її через API.

Хмарні платформи з AI-сервісами

Провайдер	Сервіс	Що вміє з документами
Google Cloud	Gemini API, Document AI	multimodal модель, OCR
Microsoft Azure	AI Document Intelligence	OCR, готові моделі документів
Amazon AWS	Textract, Bedrock	OCR, витяг полів з форм

Обрано Google Gemini API:

- OCR + розуміння, яке поле що означає, + JSON — в одному виклику; у Azure/AWS розбір тексту на поля довелося б писати самому.
- Розуміє кирилицю, двомовні й рукописні візитки.
- Безкоштовний рівень без банківської картки.

Google Gemini API

Gemini — сімейство multimodal моделей Google: текст, зображення, аудіо, відео, PDF в одному запиті.

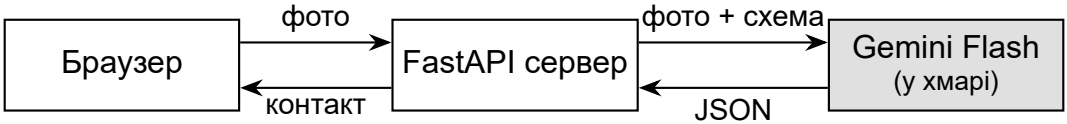
Запит = фото + промпт + JSON-схема відповіді (7 полів), `temperature=0`.

Каскад моделей — наступна, якщо попередня відповіла 429 / 500 / 503 / 504:

№	Модель	Роль
1	`gemini-3.8-flash`	основна, найновіша
2	`gemini-3.5-flash`	запасна
3	`gemini-3.5-flash-lite`	запасна, легка і швидка
4	`gemini-3.1-flash-lite`	остання надія

Gemini Developer API: ключ з `aistudio.google.com`, безкоштовний рівень без картки **(використано)**.

Архітектура



Локально (наш код)	**У хмарі (Google)**
Веб-сторінка (HTML + JS)	OCR зображення
Перевірка файлу (тип, розмір $\leq$ 10 МБ)	Розбір тексту на поля
Каскад запасних моделей	Телефони у формат +380…
Генерація файлу vCard	JSON строго за схемою

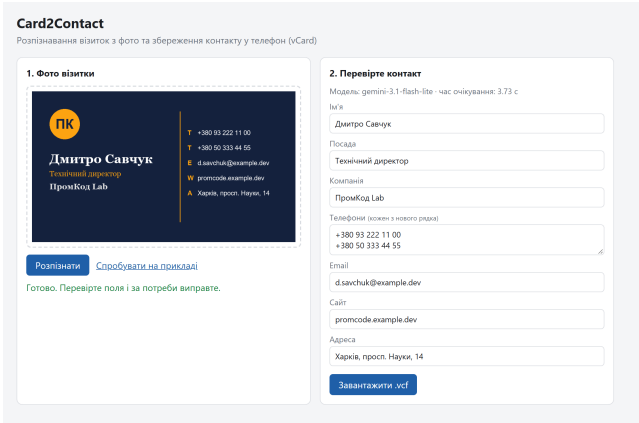
Весь «важкий» AI — на GPU Google. Наш сервер — лише тонкий шар.

Технологічний стек

Шар	Технологія
AI	Google Gemini 3.x Flash / Flash-Lite (multimodal)
SDK	`google-genai` (офіційний Python SDK)
Бекенд	Python 3.14 · FastAPI · Uvicorn
Схема даних	Pydantic — одна модель і для Gemini, і для API
Фронтенд	HTML + CSS + JavaScript, без фреймворків
Тести	pytest — 9 тестів, без мережі
Розгортання	Docker (готово до Cloud Run)

Підсумок: одна модель виконує OCR і розбір на поля — замість OCR-сервісу та власного парсера.

Веб-інтерфейс



1. Завантажити фото (drag-and-drop або вибір файлу).
2. Натиснути «Розпізнати».
3. Перевірити поля, за потреби виправити.
4. «Завантажити .vcf» — контакт імпортується в телефон.

Кнопка «Спробувати на прикладі» — демо без власного фото.

Що вміє програма

- Приймає JPG, PNG, WebP, HEIC — до 10 МБ.
- Розпізнає 7 полів: ім’я, посада, компанія, телефони, email, сайт, адреса.
- Читає українські, англійські, польські, двомовні, рукописні візитки й фото під кутом.
- Приводить телефони до міжнародного формату (`044…` → `+380 44…`).
- Не вигадує: відсутні на візитці поля лишає порожніми.
- Три способи роботи: веб-інтерфейс, CLI, REST API (`POST /api/scan`, `POST /api/vcard`, Swagger `/docs`).
- Автоматичний перехід на запасну модель при 429 / 500 / 503 / 504.

Чого не вміє

- Одна візитка і одна її сторона за раз — без пакетного режиму.
- Без історії запитів, акаунтів і автентифікації.
- Ім’я ділиться просто: останнє слово — прізвище (порядок «Прізвище Ім’я» виправляють у формі).
- Адреса — одним рядком, без розбиття на місто й індекс у vCard.
- Потрібен інтернет — уся обробка в хмарі.
- Залежить від навантаження безкоштовного рівня: зазвичай 2–8 с, у пікові години моделі відповідають 503 / 429.

Підсумок: більшість обмежень — свідомі спрощення прототипу, а не обмеження хмарного сервісу.

Перевірка якості

6 синтетичних візиток (люди вигадані) з відомими правильними відповідями; скрипт `tools/evaluate.py` порівнює 7 полів.

Візитка	Особливість	Полів	Модель	Час, с
card_uk	українська	7/7	3.5-flash-lite	2.1
card_en	англійська, США	7/7	3.5-flash-lite	3.2
card_dark	темний фон, логотип, 2 колонки	7/7	3.5-flash-lite	3.2
card_photo	фото під кутом, розмите	7/7	3.1-flash-lite	3.5
card_handwritten	рукописна, лише 3 поля	7/7	3.5-flash-lite	8.2
card_vertical	вертикальна, двомовна	7/7	3.5-flash-lite	2.8

Підсумок: 42 з 42 полів. Час — повне очікування користувача, разом зі спробами на зайнятих моделях.

Скільки це коштує

Pay-as-you-go за токени (зображення теж перетворюється на токени).

	Безкоштовний tier	**Платний tier**
Ціна	0	частки цента за візитку
Ліміт	запити на хвилину і на добу	значно вищі ліміти
Банківська картка	не потрібна	потрібна
Дані запитів	можуть покращувати продукти Google	не використовуються

Підсумок: для прототипа безкоштовного рівня вистачає. Але за вечір тестів денна квота однієї моделі закінчилась — для реальних користувачів потрібен платний рівень.

Сфери застосування

Сфера	Приклади
Нетворкінг, конференції	стос візиток $\rightarrow$ контакти за хвилини
Продажі, CRM	нові клієнти з візиток одразу в базу
HR і рекрутинг	контакти кандидатів з ярмарків вакансій
Малий бізнес	облік постачальників і партнерів
Доступність	не треба вчитуватися в дрібний шрифт

Підсумок: через відкритий API цю функцію можна вбудувати у власний продукт: CRM, месенджер, застосунок.

Як розвинути в хмарі

- **Cloud Run** — Dockerfile вже є; автомасштабування 0 $\rightarrow$ N контейнерів.
- **Google People API** — зберігати контакт одразу в Google Контакти.
- **Firebase Auth + Firestore** — акаунти та історія відсканованих візиток.
- **Cloud Storage** — зберігати фото візиток.
- **Pub/Sub або Cloud Tasks** — черга для пакетного сканування стосу візиток.
- **Secret Manager** — API-ключ замість файлу `.env`.
- **Vertex AI** — для корпоративних даних: IAM, вибір регіону, SLA, аудит.

Висновки

1. Multimodal LLM замінює ланцюжок «OCR + власний парсер полів» одним API-викликом; JSON-схема робить відповідь передбачуваною.
2. Python + FastAPI + HTML/JS — робочий сервіс без власних моделей і GPU, уся AI-робота в хмарі Google.
3. На 6 тестових візитках — 42 з 42 полів; каскад моделей рятує від перевантаження (503 / 429).
4. Проєкт — приклад AIaaS: споживаємо готову модель через API, а не хостимо власну.

Код: `https://github.com/tapa2/card2contact`