Card2Contact

Лаб. 2 «Хмарні обчислення»

Розпізнавання візиток з фото на Google Cloud: Cloud Run + Vertex AI

Тертичний Тарас, ТК-42

Проблема

Після зустрічі чи конференції — стос візиток. Переписувати кожну в телефон вручну довго, і легко помилитися в цифрі чи email.

Існуючі інструменти:

- **Google Lens** — закрите рішення, не вбудовується у власний продукт.
- **Застосунки-сканери візиток** — окремі закриті продукти, часто з підпискою.
- **Tesseract OCR** — дає суцільний текст: не знає, де ім'я, а де компанія.

Ідея: один виклик публічного multimodal AI API: фото $\rightarrow$ готові поля $\rightarrow$ файл vCard для телефону.

Штучний інтелект як хмарний сервіс

Хмара — обчислювальні ресурси за запитом з оплатою за використання.

Модель	Що надає провайдер	Приклади
IaaS Infrastructure as a Service	віртуальні машини, мережі, диски	Compute Engine, AWS EC2
PaaS Platform as a Service	**платформу для запуску коду**	**Cloud Run**, Azure App Service
SaaS Software as a Service	готовий застосунок	Gmail, Google Docs
AIaaS Artificial Intelligence as a Service	**готову AI-модель через API**	**Vertex AI**, Azure OpenAI

Підсумок: проєкт поєднує PaaS (Cloud Run) і AIaaS (Vertex AI): не купуємо сервери й GPU, не навчаємо модель.

Хмарні платформи з AI-сервісами

Провайдер	Сервіс	Що вміє з документами
Google Cloud	Vertex AI, Document AI	multimodal модель, OCR
Microsoft Azure	AI Document Intelligence	OCR, готові моделі документів
Amazon AWS	Textract, Bedrock	OCR, витяг полів з форм

Обрано Google Cloud (Gemini на Vertex AI):

- OCR + розуміння, яке поле що означає, + JSON — в одному виклику; у Azure/AWS розбір тексту на поля довелося б писати самому.
- Модель і сервер в одному проєкті: спільні білінг, IAM і логи.
- Розуміє кирилицю, двомовні й рукописні візитки.

Gemini на Vertex AI

Gemini — сімейство multimodal моделей Google: текст, зображення, аудіо, відео, PDF в одному запиті.

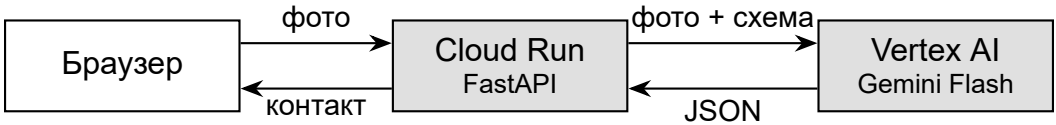
Запит = фото + промпт + JSON-схема відповіді (7 полів), `temperature=0`.

Каскад моделей — наступна, якщо попередня відповіла 429 / 500 / 503 / 504:

№	Модель	Роль
1	`gemini-3.8-flash`	основна, найновіша
2	`gemini-3.5-flash`	запасна
3	`gemini-3.5-flash-lite`	запасна, легка і швидка
4	`gemini-3.1-flash-lite`	остання надія

Vertex AI — Gemini всередині нашого проєкту Google Cloud: доступ через IAM без API-ключа, квоти й оплата проєкту, `location="global"`.

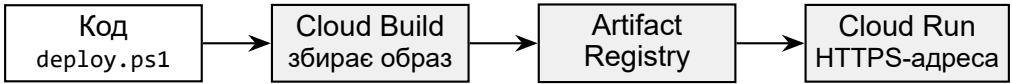
Архітектура



Cloud Run (наш код)	**Vertex AI (модель Google)**
Веб-сторінка (HTML + JS)	OCR зображення
Перевірка файлу (тип, розмір $\leq$ 10 МБ)	Розбір тексту на поля
Каскад запасних моделей	Телефони у формат +380…
Генерація файлу vCard	JSON строго за схемою

Сірим — сервіси Google Cloud. На ноутбуці нічого не працює: усе в хмарі.

Розгортання в Google Cloud



Сервіс	**Роль у проєкті**
Cloud Run	запускає контейнер, масштабує 0 → 2 копії, регіон europe-central2
Vertex AI	моделі Gemini у нашому проєкті
IAM	сервісний акаунт лише з правом `roles/aiplatform.user`
Cloud Build	збирає образ з `Dockerfile`
Artifact Registry	зберігає зібраний образ

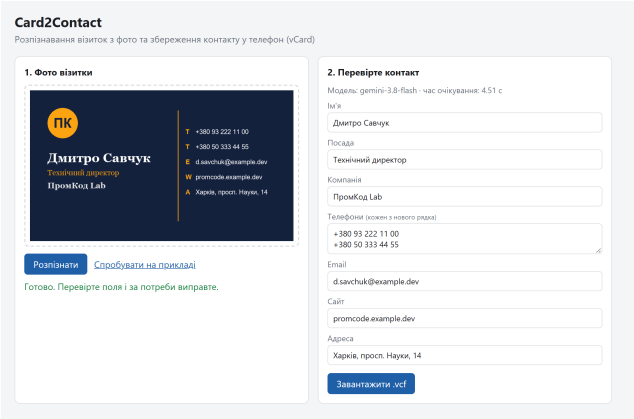
Підсумок: у застосунку немає жодного секрету: Cloud Run сам отримує короткочасні токени для сервісного акаунта.

Технологічний стек

Шар	Технологія
AI	Gemini 3.8 Flash на Vertex AI (+ 3 запасні моделі)
SDK	`google-genai` (офіційний Python SDK, `vertexai=True`)
Бекенд	Python 3.14 · FastAPI · Uvicorn
Схема даних	Pydantic — одна модель і для Gemini, і для API
Фронтенд	HTML + CSS + JavaScript, без фреймворків
Тести	pytest — 9 тестів, без мережі
Розгортання	Docker → Cloud Build → Cloud Run
Доступ	IAM сервісний акаунт; локально — `gcloud` логін (ADC)

Підсумок: одна модель виконує OCR і розбір на поля — замість OCR-сервісу та власного парсера.

Веб-інтерфейс



Скріншот з адреси Cloud Run (`card2contact-….run.app`)

1. Завантажити фото (drag-and-drop або вибір файлу).
2. Натиснути «Розпізнати».
3. Перевірити поля, за потреби виправити.
4. «Завантажити .vcf» — контакт імпортується в телефон.

Кнопка «Спробувати на прикладі» — демо без власного фото.

Що вміє програма

- Працює в хмарі за публічною HTTPS-адресою — з комп’ютера і телефона.
- Приймає JPG, PNG, WebP, HEIC — до 10 МБ.
- Розпізнає 7 полів: ім’я, посада, компанія, телефони, email, сайт, адреса.
- Читає українські, англійські, польські, двомовні, рукописні візитки й фото під кутом.
- Приводить телефони до міжнародного формату (`044…` → `+380 44…`).
- Не вигадує: відсутні на візитці поля лишає порожніми.
- Три способи роботи: веб-інтерфейс, CLI, REST API (`POST /api/scan`, `POST /api/vcard`, Swagger `/docs`).
- Автоматичний перехід на запасну модель при 429 / 500 / 503 / 504.

Чого не вміє

- Одна візитка і одна її сторона за раз — без пакетного режиму.
- Без акаунтів та історії: будь-хто з посиланням може користуватися (витрати обмежені двома копіями сервера).
- Ім’я ділиться просто: останнє слово — прізвище (порядок «Прізвище Ім’я» виправляють у формі).
- Адреса — одним рядком, без розбиття на місто й індекс у vCard.
- Перший запит після простою повільніший: Cloud Run запускає копію з нуля (холодний старт).
- Потрібен інтернет — уся обробка в хмарі.

Підсумок: більшість обмежень — свідомі спрощення прототипу, а не обмеження хмарного сервісу.

Перевірка якості

6 синтетичних візиток (люди вигадані) з відомими правильними відповідями; скрипт `tools/evaluate.py` порівнює 7 полів.

Візитка	Особливість	Полів	Модель	Час, с
card_uk	українська	7/7	3.8-flash	4.5
card_en	англійська, США	7/7	3.8-flash	12.1
card_dark	темний фон, логотип, 2 колонки	7/7	3.8-flash	5.2
card_photo	фото під кутом, розмите	7/7	3.8-flash	4.2
card_handwritten	рукописна, лише 3 поля	7/7	3.8-flash	6.0
card_vertical	вертикальна, двомовна	7/7	3.8-flash	6.1

Підсумок: 42 з 42 полів через Vertex AI. Основна модель відповіла на всі запити — запасні не знадобились.

Скільки це коштує

Pay-as-you-go: платимо лише за використання, без серверів і підписок.

Сервіс	За що платимо	Для лаби
Vertex AI	токени запиту й відповіді (фото теж токени)	частки цента за візитку
Cloud Run	час обробки запитів; 0 копій — 0 оплати	у межах безкоштовної квоти
Cloud Build	хвилини збирання образу	кілька хвилин на деплой
Artifact Registry	зберігання образу	сотні МБ

Підсумок: прототип працює на стартових trial-кредитах. Захист від несподіваних витрат — максимум 2 копії сервера і бюджет-сповіщення в Billing.

Сфери застосування

Сфера	Приклади
Нетворкінг, конференції	стос візиток $\rightarrow$ контакти за хвилини
Продажі, CRM	нові клієнти з візиток одразу в базу
HR і рекрутинг	контакти кандидатів з ярмарків вакансій
Малий бізнес	облік постачальників і партнерів
Доступність	не треба вчитуватися в дрібний шрифт

Підсумок: через відкритий API цю функцію можна вбудувати у власний продукт: CRM, месенджер, застосунок.

Як розвинути в хмарі

- **Firebase Auth + Firestore** — акаунти та історія відсканованих візиток.
- **Google People API** — зберігати контакт одразу в Google Контакти.
- **Cloud Storage** — зберігати фото візиток.
- **Pub/Sub або Cloud Tasks** — черга для пакетного сканування стосу візиток.
- **Cloud Monitoring** — сповіщення про помилки й повільні відповіді.
- **Власний домен + Cloud Armor** — гарна адреса й обмеження частоти запитів.
- **CI/CD** — автоматичний деплой у Cloud Run після кожного push у GitHub.

Висновки

1. Multimodal LLM замінює ланцюжок «OCR + власний парсер полів» одним API-викликом; JSON-схема робить відповідь передбачуваною.
2. Сервіс повністю в Google Cloud: Cloud Run (PaaS) + Vertex AI (AIaaS) — без власних серверів, GPU і API-ключів; доступ видає IAM.
3. На 6 тестових візитках — 42 з 42 полів; каскад моделей — страховка від 503 / 429.
4. Розгортання одним скриптом: Cloud Build → Artifact Registry → Cloud Run.

Сервіс: `card2contact-61425642502.europe-central2.run.app`

Код: `github.com/tapa2/card2contact`